ChatGPT

Tóm tắt nghiên cứu

Schrödinger Bridge (SB) là một công cụ tạo mẫu sinh (generative) dựa trên tối ưu vận chuyển có chuẩn hoá entropy (entropy-regularized optimal transport) trên không gian quỹ đạo ngẫu nhiên【6†L29-L34】. Bài báo này đề xuất ứng dụng SB vào hai hướng chính trong hệ thống UAV và truyền thông semantic không dây:

- **(A) SwarmBridge – Hồi quy latent ngữ nghĩa đa UAV và chọn UAV/giao thức:** Dùng SB có điều kiện (conditional SB) để khôi phục biểu diễn ngữ nghĩa đầy đủ từ các quan sát bị thiếu hoặc bị hỏng (do kênh kém), đồng thời sử dụng bất định do SB cung cấp để hướng dẫn chọn UAV hỗ trợ và chế độ truyền thích hợp (bit truyền gốc, text mô tả, hoặc text+đặc trưng)【29†L481-L490】【22†L25-L34】. Điểm mới là tích hợp vòng kín: *SB ước lượng phần thông tin còn thiếu, từ đó hệ thống quyết định yêu cầu UAV nào truyền thêm bằng chứng cần thiết* (giảm thiểu băng thông và độ trễ mà vẫn đạt chất lượng nhiệm vụ).

- **(B) SB cho điều khiển/RL quỹ đạo UAV:** Áp dụng ý tưởng SB (hoặc KL trên không gian đường đi) vào bài toán điều khiển bay ngẫu nhiên. Ta chọn một quá trình tham chiếu φ (dynamics cơ bản hoặc chính sách nền) rồi tìm chính sách/cỗ máy điều khiển khiến phân phối quỹ đạo đạt mục tiêu mong muốn với chi phí KL thấp nhất. Cách tiếp cận này liên quan đến lý thuyết điều khiển có năng lượng dạng L_2 và RL có chuẩn hoá KL (ví dụ linearly-solvable MDP hoặc Path Integral control), đồng thời có thể kết hợp mục tiêu phân phối hình thành đội hình mong muốn.

Báo cáo so sánh SB với các phương pháp khác: diffusion (score-based SDE), flow matching (vector field ODE), và phương pháp phân lớp trực tiếp (mappings) cả về lý thuyết lẫn thực nghiệm. SB thích hợp khi ta có hai phân phối biên cụ thể và cần tạo quá trình sinh mẫu tương ứng【6†L29-L34】【8†L23-L31】. Flow matching (FM) huấn luyện một trường vectơ (ODE) để dịch chuyển chính xác giữa hai phân phối, không thêm nhiễu ngẫu nhiên, cho phép suy luận nhanh bằng solver ODE【13†L23-L32】. Diffusion (SDE) cần nhiều bước thời gian để tiếp cận phân phối đích, nhưng dễ huấn luyện qua score matching. Bản đồ trực tiếp (mapping) rẻ và nhanh nhưng không cung cấp ước lượng bất định.

Về thực nghiệm **SwarmBridge (Q1→Q2→Q3)**, chúng ta sẽ khởi đầu với kịch bản Town3 (CoPerception-UAV, 5 UAV bay tản ra). Các UAV dùng chung encoder semantic (ra latent) và mã hoá rời rạc, rồi truyền qua kênh giả lập (AWGN, suy yếu hằng giây và mất gói). Ở đầu thu, ta có latent $\mathbf{z_p}$ (bị hỏng) của từng UAV và thông tin CSI (SNR, mask mất gói). Ta huấn luyện SB có điều kiện để sinh latent đầy đủ $\mathbf{z}\bigstar$ (theo mục tiêu và CSI), đo chất lượng trên tác vụ BEV segmentation (mIoU) và đánh giá bất định (AUROC, AURC, ECE). Baseline bao gồm regression mapping (với/không CSI), flow matching, và SB tiêu chuẩn (nhiễu đẳng hướng). Nếu SB không vượt qua baselines này về accuracy, nhưng cho bất định tốt hơn, ta chuyển hướng sang Q2 (chọn UAV dựa trên bất định và giá trị thông tin). Nếu SB thua hẳn, chúng ta pivot sang dùng các mô hình đơn giản hơn cho vòng giao tiếp.

Về **quyết định và điều khiển (Q2/Q3)**, ta sẽ xây dựng hàm utility $$ V(j,m)\;=\;\mathbb{E}[\Delta U_{\mathrm{task}}\mid j,m,b_t]\;-\;\lambda_B B_{j,m}\;-\;\lambda_E E_{j,m}\;-\;\lambda_L L_{j,m}, $$ trong đó j là UAV, m là chế độ (bit/text/feat), ΔU_{task} là lợi ích nhiệm vụ kỳ vọng khi nhận thông tin từ (j,m), và B,E,L là chi phí bitrate, năng lượng, trễ. SB giúp tính toán $\mathbb{E}[\Delta U]$ bằng cách mô phỏng belief sau khi nhận thông tin. Kế hoạch là thử các chính

sách đơn giản (ví dụ contextual bandit, DSAC như Huang et al. đề xuất【22†L25-L34】) để chọn (j,m) dựa trên SB-ước lượng.

Báo cáo trình bày chi tiết về: **(1)** Đọc tài liệu ưu tiên (các bài về diffusion/SB, flow matching, SemCom swarm) với tóm tắt ngắn; **(2)** Thiết kế thí nghiệm Q1 (Town3) gồm pipeline, baseline, ngân sách huấn luyện, kill-criterion; **(3)** Mô hình kết hợp SB để ước lượng lợi ích nhiệm vụ cho chọn chế độ truyền, công thức $V(j,m)$; **(4)** Các quá trình tham chiếu khả dĩ: (i) latent SB: Brownian, SDE dị hướng theo CSI, SDE học được (pros/cons); (ii) flight SB: động lực UAV ngẫu nhiên, chính sách nền; **(5)** Gợi ý code/phần cứng và timeline 8–12 tuần; **(6)** sơ đồ kiến trúc và lưu đồ mermaid; **(7)** hướng bước tiếp theo và kịch bản quyết định nếu SB thất bại. Tất cả kèm chú thích nguồn chuẩn【6†L29-L34】【8†L23-L31】【13†L23-L32】【19†L24-L32】【33†L23-L27】 để đảm bảo tính chính xác.

---

1. Đọc tài liệu ưu tiên

Để hiểu SB và các phương pháp cạnh tranh, cần nắm các công trình cốt lõi sau:

- **De Bortoli et al. (NeurIPS 2021)** – *"Diffusion Schrödinger Bridge"*【6†L29-L34】. Giới thiệu SB trong ngữ cảnh generative modeling: phân biệt với diffusion SDE thông thường bằng việc không cần chạy SDE quá lâu. SB giải bài toán OT có entropy trên đường đi và cho phép tạo mẫu trong thời gian hữu hạn【6†L29-L34】. Đây là nền tảng lý thuyết để áp dụng SB cho generative.
- **Liu et al. (ICML 2023)** – *"I^2SB: Image-to-Image Schrödinger Bridge"*【8†L23-L31】. Đề xuất SB có điều kiện (Image-to-Image SB) cho khôi phục ảnh: học một quá trình phân phối có biên $x_{\mathrm{deg}} \to x_{\mathrm{clean}}$. Cho kết quả tốt hơn diffusion có điều kiện truyền thống và khả năng tính được phân phối biên giữa các bước một cách giải tích. Nghiên cứu này sát với bài toán của chúng ta (khôi phục latent bị mất).
- **Lipman et al. (TMLR 2023)** – *"Flow Matching for Generative Modeling"*【13†L23-L32】. Giới thiệu Flow Matching (FM): mô hình CNF huấn luyện bằng cách khớp trường véc-tơ cố định, cho phép chọn bất kỳ đường đi xác suất nào (bao gồm diffusion) để tập huấn. Một trường hợp đặc biệt là dùng nội suy OT tối ưu, cho hiệu quả cao và khởi tạo mẫu nhanh (ODE solver) với quality tốt hơn diffusion. FM có thể được coi như đối thủ với SB: FM sinh mẫu *deterministic*, SB (cũng như diffusion) sinh mẫu *stochastic* với training dễ dàng hơn nhưng inference có nhiều bước.
- **Hu et al. (NeurIPS 2022)** – *"Where2Comm"*【19†L24-L32】. Không dùng SB nhưng liên quan đến SemCom đa tác tử. Đề xuất "bản đồ độ tin cậy không gian" để chỉ gửi thông tin khu vực quan trọng giữa các agent. Cho thấy tầm quan trọng của việc "chỉ gửi những gì thật sự cần" khi băng thông hạn chế. Work này làm tốt về tối ưu băng thông và độ chính xác phát hiện trong perception hợp tác. Đây là tiền đề chọn UAV dựa vào tín nhiệm (confidence) như bài toán Q2 của chúng ta.
- **Huang et al. (2024, JSAC)** – *"Hybrid Bit and Generative Semantic Comms in SAGIN"*【22†L25-L34】【29†L481-L490】. Mô tả một framework SAGIN gồm LEO, UAV, người dùng; có ba chế độ truyền (bit truyền ảnh, text mô tả ảnh, text+embedding)【29†L481-L490】. Dùng DRL (DSAC) để chọn thiết lập truyền nhằm tối ưu trade-off chất lượng ảnh và độ trễ【22†L25-L34】. Tài liệu này minh hoạ kịch bản hybrid bit/text/image, các biện pháp đánh giá kết quả (PSNR, delay metric, SCE) và cách tích hợp DRL. Chúng ta mượn ý thức này để đưa vào Q3.
- **Jukić et al. (Interspeech 2024)** – *"Schrödinger Bridge for Speech Enhancement"*. Dù cụ thể cho speech, cho ví dụ việc dùng SB như mô hình sinh để tái tạo tín hiệu phóng đại từ tín hiệu bị suy giảm (vốn là SemCom analog). Nghiên cứu này cho thấy SB có thể dùng làm bộ khôi phục tín hiệu trên channel kém.

- **Yang et al. (InterSpeech 2026)** – *"Schrödinger Bridge Mamba"*. Cũng không bắt buộc, nhưng ví dụ họ dùng SB để map latent của codec âm thanh giữa hai độ phân giải khác nhau. Gợi ý ý tưởng *BridgeCodec* (dịch latent giữa các định dạng).

Ngoài ra, cần tham khảo các bài score-based và flow để hiểu sự khác biệt: **Song et al. (2020)** về generative SDE score-based, **Ho et al. (2020)** DDPM, **JKO** hay **Monge–Ampère flows** cho ý tưởng ODE. Tuy nhiên, đọc De Bortoli 2021【6†L29-L34】, Liu 2023【8†L23-L31】, Lipman 2023【13†L23-L32】 và các tài liệu SemCom như Huang 2024【22†L25-L34】【29†L481-L490】, Where2Comm【19†L24-L32】 sẽ là ưu tiên số một, vì chúng chứa đủ các khái niệm và giải pháp liên quan.

Đọc ngắn gọn: De Bortoli (SB) cho khái niệm SB và lý thuyết phức tạp của nó【6†L29-L34】. Liu (I^2SB) cho ứng dụng SB có điều kiện cho khôi phục hình ảnh【8†L23-L31】. Lipman (FM) đưa ra mô hình flow mapping không noise【13†L23-L32】. Hu (Where2Comm) và Huang (SAGIN) cho bối cảnh SemCom đa tác tử/hybrid, đánh giá hiệu quả giao tiếp, lựa chọn thông tin cần gửi【19†L24-L32】【22†L25-L34】.

---

2. Thiết kế thí nghiệm Q1 (Town3)

Kịch bản mô hình: Dựa trên Town3 của CoPerception-UAV【33†L21-L29】, giả sử có N UAV (ví dụ 5) bay tản đều ở độ cao khác nhau, mỗi UAV chỉ quan sát một vùng riêng (đường, nhà, xe cộ). Mỗi UAV có encoder **E** chung để mã hoá ảnh từ camera thành vector latent semantic $z_i \in \mathbb{R}^d$. Trước khi truyền, ta có thể áp dụng lượng tử hóa hoặc VectorQuantizer (VQ) để giảm bitrate. Qua kênh, mỗi UAV gửi một số token bit. Kênh có mô hình AWGN và Rayleigh fading, kèm cơ chế mất gói ngẫu nhiên (packet erasure); từ đó tạo ra một bản đồ độ tin cậy $\mathbf{r}$ (ví dụ $r_k=1$ nếu token thứ k được nhận, 0 nếu mất). Đầu thu (có thể là một UAV leader hoặc base station) nhận được các latent $z_{p,i}$ của mỗi UAV (mỗi cái có phần thiếu do mất gói, tỉ lệ phụ thuộc SNR và số tầng bị mất). Đầu thu tích hợp thông tin CSI về channel (SNR, mask r) và nhiệm vụ (task) đang cần (ví dụ BEV segmentation của toàn cảnh) để xử lý tiếp.

Giải pháp đề xuất: Học một mô hình SB có điều kiện (conditional SB) $z_p \to z^$ *sao cho nếu đủ thông tin, ta thu được biểu diễn oracle $z*^$ dùng cho task. Cụ thể, trong huấn luyện ta giả sử có "giáo viên" tập trung: ta tạo bản đồ BEV đầy đủ $z^$ *bằng cách ghép thông tin sạch từ tất cả UAV (như kính hiển vi teacher). SB học cầu nối quãng đường giữa μ_0 (phân phối của z_p có điều kiện trên tình trạng channel $c=(\mathrm{CSI},\mathrm{task},\mathrm{mask})$) và μ_1 (phân phối của $z*^$ có cùng điều kiện). Ta có thể đơn giản hoá μ_0 thành delta tại điểm z_p quan sát được, rồi SB sẽ học drift $\eta(z,t;c)$ hoặc score $\nabla \log p$ sao cho với một quá trình tham chiếu R (ví dụ Brownian) ta đạt $Z_{t=1}\sim z^$*. Khác biệt lớn của Q1a là chọn reference R có tính kênh**: tức là R có thể có cường độ nhiễu và drift thay đổi theo độ tin cậy dữ liệu, thay vì Brownian đẳng hướng.

Pipeline cụ thể (một chú thích bằng hình):

```
flowchart LR
    subgraph UAVs
        UAV1([UAV 1]) -- quan sát --> E((Shared Encoder))
        UAV2([UAV 2]) -- quan sát --> E
        UAV3([UAV 3]) -- quan sát --> E
    end
    E -- semantic z_p --> Q((Quantizer/VQ))
    Q -- indices --> TX(Wireless Channel)
    TX -- (z_p, \mathbf{r}) --> RX((Receiver (Leader)))
```

```
RX -- (latent z_p, CSI \mathbf{r}) --> SB(Schrödinger Bridge)
SB -- (z^*) --> Task(Task Head / BEV Segmentation)
SB -- (uncertainty) --> H(Helper/Mode Scheduler)
style UAV1 fill:#cff,stroke:#333
style UAV2 fill:#cff,stroke:#333
style UAV3 fill:#cff,stroke:#333
style E  fill:#cfc,stroke:#333
style Q  fill:#fcf,stroke:#333
style TX fill:#fcc,stroke:#333
style RX fill:#ccf,stroke:#333
style SB fill:#cff,stroke:#333
style Task fill:#ffc,stroke:#333
style H fill:#cfc,stroke:#333
```

Trong pipeline này, **SB** là mô hình chính được học; nó tạo ra latent khôi phục $\hat z^*$ và cung cấp độ bất định ở ngưỡng nhận. Mô-đun Scheduler (Q2) sử dụng độ bất định của SB để quyết định có cần thêm thông tin từ UAV nào.

Baseline: Chạy song song các phương án sau để so sánh:

- **Mapping trực tiếp (M):** Dùng mạng nơ-ron hồi quy để học $z_p \mapsto z^*$, có thể đưa CSI (SNR) vào như một đầu vào phụ. Đánh giá xem SB có cần thiết không.
- **Mapping + augment:** Hồi quy tương tự nhưng khi train thêm nhiễu (ví dụ từ $\mathbf{r}$) lên latent như augmentation dị hướng. Nếu SB không hơn hơn phương pháp đơn giản này, đóng góp sẽ hạn chế.
- **Flow Matching (F):** Học một trường véc-tơ tương ứng với một đường đi xác suất (chọn Brownian path hoặc nội suy OT) để dịch từ z_p sang z^*【13†L23-L32】. Đây là phương thức determinisitc (ODE) đối thủ với SB. Dùng NFE nhỏ (4–10) để so sánh nhanh.
- **SB chuẩn (S0):** SB isotropic với Brownian reference $dZ_t=\sqrt{\varepsilon}\,dW_t$. (Sai biệt rằng SB này tối ưu hoá KL trên quỹ đạo).
- **SB có điều kiện (S1):** SB isotropic nhưng mạng neural nhận thêm thông tin CSI.
- **SB tham chiếu kênh (S2):** SB với R có nhiễu theo mật độ dựa trên $\mathbf{r}$ (tức vùng ít tin cậy có nhiễu lớn hơn). So sánh với S1 để kiểm chứng Q1a.
- **SB tham chiếu thực nghiệm (S3):** Tùy chọn đường đi tham chiếu empiric (VD: dùng SDE với drift ngược để giảm khoảng cách latent).
- **Heteroscedastic mapping:** Bản đồ hồi quy $z_p \to (\mu, \sigma^2)$, học phân phối lỗi. Đây là baseline để so sánh chất lượng bất định.

Ngân sách huấn luyện: Cấu hình ban đầu đề xuất: dùng GPU ~12–16 GB, tối ưu với PyTorch. Huấn luyện mỗi model ~10k bước, 3 seed khác nhau, sớm dừng khi convergent. NFE cho SB được điều chỉnh (1, 4, 10 bước) để kiểm tra hiệu quả. Đầu ra SB có thể là U-Net với UQ head hoặc Transformer (tùy resource). Dự kiến Town3 (~1.7k lưới) cho phép chạy nhanh (trong vài giờ).

Đánh giá: Ta đo **mIoU (BEV segmentation)** giữa kết quả task sử dụng $\hat z^$ *và mặt đất (trần là model có $z*^$ sạch). Đồng thời tính **AUROC, AURC, ECE** của độ tin cậy SB đối với lỗi task. Đánh giá overhead bằng **số bit truyền** (tổng token) và **độ trễ suy luận** (NFE). Tính toán **Spearman**, top-1/NDCG khi dùng độ tin cậy để chọn UAV so sánh với lựa chọn lý tưởng ΔU_{task} (Q2 metrics).

Kill Criterion (Q1): Nếu cả SB isotropic lẫn SB channel-aware không vượt baseline mapping về mIoU trong điều kiện channel xấu (vd. severe SNR), tức SB không sinh lợi, ta dừng. Nếu SB không cải thiện được mô hình đơn giản, ý tưởng kém khả thi. Nếu SB isotropic thua nhưng SB channel-aware thắng

(Q1a) là tín hiệu tốt. Ngược lại, nếu SB isotropic thua baseline mapping nhưng SB channel-aware vẫn thua, thì SB có lẽ không đem lại nhiều lợi ích. Riêng bất định (Q1b) chỉ có ý nghĩa nếu SB cho độ tin cậy tốt hơn đáng kể so với baseline: cần so sánh AUROC(SB) vs AUROC($1-r$) và vs heteroscedastic mapping.

Cẩn trọng: Dữ liệu Town3 ít chồng lặp giữa UAV, nên SB ở đây chủ yếu học khử nhiễu channel cho từng UAV (gần với bài toán "cải thiện tín hiệu sau kênh" hơn là multi-source fusion). Phần thật giá trị mới sẽ tập trung vào Q1a (reference-aware SB) và Q1b (uncertainty thực sự). Tuy nhiên, chúng ta sẽ thiết lập bảng đánh giá rằng: *dù Town3 không có vùng overlap lớn, hệ thống vẫn phải chia băng thông hạn chế cho 5 UAV. Điều kiện tài nguyên này được phản ánh qua việc vẽ kết quả theo tổng bit và số UAV hoạt động.* Nếu SB có thể duy trì mIoU cao trong khi giảm số UAV cần truyền (hoặc tổng bits), đó cũng là thành quả quan trọng.

---

3. Kết hợp SB để lựa chọn chế độ truyền (Q3)

Trong kịch bản hybrid bit/text/image, mỗi UAV j ở thời điểm t có các lựa chọn truyền thông tin dạng:

- **Mode 1:** Gửi ảnh gốc đã nén (bit truyền truyền thống).
- **Mode 2:** Gửi text miêu tả ảnh (thông tin ngữ nghĩa cao, bitrate thấp, chất lượng thấp).
- **Mode 3:** Gửi text + đặc trưng ảnh (medium bitrate, chất lượng phục hồi tốt hơn)【29†L481-L490】.

Ta định nghĩa utility mong đợi khi UAV j gửi chế độ m như $$ V(j,m)\;=\;\mathbb{E}[\Delta U_{\text{task}}\mid j,m,b_t] -\lambda_B B_{j,m}-\lambda_E E_{j,m}-\lambda_L L_{j,m}, $$ trong đó $ \Delta U_{\text{task}}$ là mức cải thiện tín nhiệm/năng suất nhiệm vụ kỳ vọng (ví dụ tăng mIoU BEV), B là số bit (giá kênh), E năng lượng, L trễ (cả thời gian truyền và xử lý). SB giúp ước lượng $ \mathbb{E}[\Delta U_{\text{task}}\mid j,m,b_t]$ bằng cách mô phỏng posterior belief sau khi nhận thông tin từ (j,m). Cụ thể, ta có thể huấn luyện một SB (hoặc mô hình Bayesian) để tiên đoán latent đích z^* có điều kiện trên b_t và thông tin bổ sung giả định được gửi từ (j,m); từ đó tính được cải thiện nhiệm vụ.

Ví dụ: Receiver hiện tin rằng vùng phía trước có thể chứa xe nhưng không chắc chắn. UAV j có thể gửi bản đồ semantic patch của vùng đó. SB dự đoán belief mới nếu dữ liệu đó được nhận. Trả về ΔU là độ tăng kỳ vọng trong mIoU hoặc xác suất phát hiện.

Một khi có $V(j,m)$ cho mọi UAV j và chế độ m, ta chỉ cần chọn $(j^,*m*^)=\arg\max V(j,m)$ để yêu cầu truyền. Thử nghiệm ban đầu có thể dùng **contextual bandit** (ưu tiên UAV có V cao) hoặc DRL (ví dụ DSAC) để học chính sách $(j,m)\sim \pi(b_t)$. Bài toán Q3 sẽ so sánh các chiến lược như ϵ-greedy dựa trên $V(j,m)$, contextual bandit, và phương pháp DSAC (giống Huang 2024【22†L25-L34】) nhằm tối ưu trade-off giữa mIoU và tài nguyên.

Một công thức đơn giản hơn: tính thông tin ngữ nghĩa I_j hàm số độ tin cậy/độ bất định do SB cung cấp trên vùng của UAV j. Đối với mỗi chế độ m, đánh giá lợi ích tương đương $V(j,m)=I_j - \lambda_B B_{j,m} - ...$. Thậm chí nếu không dùng SB, ta có thể so sánh với baselines như lợi ích cho bởi $\Delta(1-r)$ (giả thiết mất gói) hoặc phương pháp heuristic như Mahalanobis trong latent.

Tóm lại, SB giai đoạn Q3 chủ yếu đóng vai trò mô hình dự đoán khi thực hiện từng lựa chọn truyền. Kết hợp với chính sách RL hoặc hàm utility trên, chúng ta xây dựng hệ thống chọn UAV/chế độ hiệu quả.

4. Tham số tham chiếu (Reference process)

4.1. Latent SB (semantic)

Với bài toán khôi phục latent semantic, tham số tham chiếu $\mathbb{R}$ nên định nghĩa trên **không gian latent**. Các lựa chọn khả thi:

- **Brownian Motion (đẳng hướng):** $dZ_t=\sqrt{\sigma^2}dW_t$ (phiến phân phối chuẩn, tỉ lệ nhiễu đồng nhất). Cách đơn giản nhất, từng dùng trong các mô hình diffusion và SB cơ bản 【6†L29-L34】. Ưu điểm: đơn giản, lý thuyết rõ ràng (Brownian bridge analytic giữa hai điểm xác định); dễ hiện thực. Nhược: không phản ánh hình học latent và không dùng CSI. Là baseline cho SB tiêu chuẩn.

- **SDE kênh-aware (độ tin cậy):** Thiết kế drift/diffusion phụ thuộc chất lượng kênh $c=(\mathrm{CSI},\mathbf{r})$. Ví dụ: $$dZ_t = b_{\text{ref}}(Z_t,t;c)\,dt + \sqrt{G(t;c)}\,dW_t.$$ Ta có thể chọn G tăng ở tọa độ latent kém tin cậy (where $r_k=0$), khiến quá trình tham chiếu thêm nhiễu ở vùng đó. Drift $b_{\rm ref}$ có thể làm mờ dần latent mờ đi hoặc dịch về latent dự kiến. Ý tưởng: cho xem dạng covariance thích nghi theo CSI. Ưu: Mô phỏng độ tin cậy cục bộ hơn, nếu khung giả thuyết đúng (Q1a) sẽ ít bước hơn để hội tụ. Nhược: phức tạp, có thể sinh quá nhiều hyper-parameters, và có thể không cải thiện đáng kể nếu mạng SB đã đủ học từ CSI.

- **Học tham chiếu:** Học một quá trình tham chiếu $\mathbb{R}$ qua mạng (ví dụ VAE hoặc diffusion phụ) để phản ánh đặc tính dữ liệu latent. Có thể huấn luyện một mô hình tầng sâu phụ vừa làm reference process. Rất mới và khó: có thể tăng hiệu năng nhưng cần chứng minh bằng thực nghiệm.

Trong nghiên cứu khởi đầu, chọn Brownian đơn giản làm baseline. Nếu cải thiện từ $R_{\rm channel}$ (như Claude gợi ý) không rõ rệt, ta đơn giản hoá về SB isotropic. Quan trọng phải test qua các ablation: so sánh SB isotropic, SB with CSI-input (network), SB with channel-dependent noise. Cần lưu ý kết luận của Claude rằng: nếu SB với Brownian thua mapping, có thể SB chưa có lợi ích, nên ưu tiên dùng Brownian ban đầu.

4.2. SB cho quỹ đạo (flight)

Ở đây không gian trạng thái là không gian vật lý (vị trí, vận tốc UAV). Tham chiếu $\mathbb{R}$ nên là phân phối đường đi UAV khi bay theo một động lực nền. Ví dụ:

- **Dynamics cơ bản:** Lấy SDE cho UAV:

$$dq = v\,dt, \quad dv = f_{\text{phys}}(q,v)\,dt + \Sigma\,dW_t.$$

  Ví dụ $f_{\rm phys}$ là một controller bay theo đường thẳng hay formation holding, Σ biểu diễn nhiễu (gió, model thiếu sót). Reference $\mathbb{R}$ là quỹ đạo thu được nếu UAV bay với $f_{\rm phys}$ và nhiễu ΣdW. Sau đó SB sẽ học điều chỉnh $f_{\rm phys}$ bằng control thêm η để đạt mục tiêu (vd. hình thành đội, theo dõi đối tượng) sao cho KL tối thiểu. Khi đó

$$D_{KL}(P\|\mathbb{R}) = \frac{1}{2}\mathbb{E}\int_0^T \|\eta_t\|^2_{\Sigma\Sigma^\top}\,dt,$$

tương tự form của điều khiển dạng hội tụ đường ray (điều kiện F-K).

- **Chính sách nền:** Nếu dùng MDP rời rạc, lấy $\mathbb R$ là phân phối đường đi do chính sách $\pi_{\rm ref}$ (ví dụ greedy safe policy). Ta tìm chính sách π mới để tối ưu điều kiện ràng buộc phân phối đầu-cuối. Khi dynamics giống nhau, tối thiểu $D_{KL}(P_\pi|\mathbb R) = \mathbb{E}\sum \log(\pi(a|s)/\pi_{\rm ref}(a|s))$【24†】. Đối tượng bài toán là KL-regularized RL.

- **Đồng hóa SB và RL:** Nếu muốn SB đúng nghĩa, ta có thêm ràng buộc phân phối đầu-cuối (ví dụ đường bay bắt đầu tại nhà và phải kết thúc trong vùng mục tiêu). Lúc đó phải giải problem Schrödinger Bridge dạng liên tục. Tuy nhiên, trong RL thực tế thường bỏ ràng buộc bên cuối, thay vào đó gộp KL vào reward (Lagrange). Kết quả là bài toán cải thiện policy với thưởng entropy.

Ưu/nhược: Tham chiếu bay thực giúp kết quả bay khả thi (tôn trọng băng thông UAV, tránh đâm va). Brownian (đơn giản) không phù hợp với vật lý bay. Nhiệm vụ là chọn tham chiếu phản ánh động lực UAV: VD như ổn định cấp tốc, hoặc theo đường đi an toàn với nhiễu nhỏ. Sau này có thể dùng SB để lập cổng bay thăm dò (Exploration) hoặc phi-cần-đón.

---

5. Các thành phần triển khai, pipeline và timeline

Khung phần cứng: Dự kiến dùng PyTorch hoặc JAX cho mô hình SB; mã hóa latent bằng CNN hoặc Transformer (tùy dataset). GPU tối thiểu 12–16 GB (ví dụ V100 16GB hoặc A100 40GB) để huấn luyện SB và inference, đặc biệt nếu dùng U-Net lớn hay Transformer. Town3 nhỏ (96×96 latent) nên card ~12GB là đủ. Đối với dataset lớn (CoPerception), dùng GPU 24+GB để batch lớn. Mã hóa semantic: có thể tận dụng pretrained encoder (như LXMERT/CLIP) và freeze, chỉ học phần SB.

Pipeline cơ bản: 1. **Chuẩn bị dữ liệu:** Dùng CoPerception-UAV Town3 (Town 3), có sẵn label BEV segmentation【33†L102-L106】. Huấn luyện một mạng đầu vào sạch: ảnh BEV → nhãn (mIoU >0.82 theo ví dụ) để lấy latent ground-truth $z^$. *Sau đó lưu cache $z*^$ và tính z_p (áp kênh giả lập, mất gói) cho tập train/val. Mỗi sample bao gồm $(z_p,z^,\mathbf{r})$.*
2. Mô phỏng kênh: Tạo module channel: thêm AWGN, Rayleigh fading (Rician) và ngẫu nhiên loại bỏ token với xác suất theo SNR. Tính toán tỷ lệ bit nhận được (bit/frame).
3. Xây SB: Làm như I²SB hoặc Song SDE: Huấn luyện mạng U-Net (hoặc GAN nhỏ) thành phần score hoặc drift. Điều kiện hóa bằng $(z_p,\mathbf{r},\mathrm{task})$. Có thể huấn luyện theo IPF bằng các cặp $(z_p,z*^)$ và giả lập đường Brownian giữa chúng. Phương pháp training giống diffusion (denoising) nhờ công thức đường bắc cầu (bridge)【6†L29-L34】【8†L23-L31】.
4. **Đánh giá:** Lưu mIoU, AUROC v.v. theo từng seed, NFE. Vẽ mIoU theo tổng bit và theo số UAV hoạt động để biểu diễn khả năng mở rộng (scale) và tiết kiệm tài nguyên.
5. **Chọn chế độ (giai đoạn kế):** Triển khai module tính utility $V(j,m)$, thử chính sách đơn giản (bandit, DSAC).

Framework/Kho lưu trữ: Có thể tận dụng repo SB gốc của De Bortoli hay code của I2SB (thường công bố trên GitHub). For flow matching, không cần thư viện đặc biệt, chỉ cần ODE solver (như torchdiffeq). Cho phần scheduler, có thể dùng Stable Baselines 3 (DSAC) hoặc tự code PPO.

Thời gian (8–12 tuần):

```
gantt
    dateFormat  YYYY-MM
    title      L\u1edbn d\u01b0\u1edbp (Timeline) cho nghiên cứu SB - UAV
SemCom
    2026-11  : chuẩn bị & thử nghiệm ban đầu
    2026-12  : triển khai Baseline Mapping/Flow (Q1)
    2027-01  : hu\u1ec9 luy\u1ec7n SB isotropic, đo l\u01b0u \u0111\u1ed1i
    2027-02  : SB channel-aware, ablation & \u0111\u00e1nh gi\u00e1
    2027-03  : ph\u00e2n t\u00edch k\u1ef3, quy\u1ec1t \u0111\u1ecbnh
ti\u1ebfp t\u1ee5c (Q2/Q3)
    2027-04  : x\u00e2y dựng scheduler, th\u1ef1c nghi\u1ec7m h\u01b0\u1edfng
Hybrid (DRL)
    2027-05  : đánh giá to\u00e0n b\u1ed9, vi\u1ebft b\u00e1o c\u00e1o
```

Hình trên mô tả lịch trình sơ bộ: ban đầu 2 tháng đầu tập trung Q1 trên Town3, 2 tháng kế tiếp xây Q2/Q3, sau cùng hoàn thiện báo cáo. Mốc *Checkpoint* quan trọng là kết quả Q1: nếu SB thất bại (mapping tốt hơn rõ) thì pivot, nếu thành công sẽ tiếp tục chi tiết phần hội tụ và RL.

---

6. So sánh và bàn luận

Các thuộc tính so sánh chính:

- **Task/Công việc:** BEV segmentation (town3), 3D detection (OPV2V/V2X), semantic segmentation, tracking – tùy dataset【33†L23-L27】【19†L37-L43】.
- **Datasets:** *Town3 (CoPerception-UAV)*: 5 UAV, BEV seg (road, building, vehicle, other)【33†L102-L106】. *OPV2V/V2X-Sim*: khảo sát perception đa agent giao thông【19†L37-L43】. (Nếu có, *UAV3D* hoặc *DAIR-V2X*).
- **Kênh:** Mô phỏng AWGN + Rayleigh (Rician) + block erasure (mất gói). SNR thử nghiệm từ rất thấp (severe) đến cao (easy) để đánh giá robustness.
- **Các phương pháp:** Detal mapping, det.gen (“flow”), diff (SB, score), SB điều kiện. Bảng so sánh:

Phương pháp	Đặc điểm	Ưu/Nhược chính
Định tuyến trực tiếp (Mapping)	Mạng DNN trực tiếp học $z_p\to z^*$ (hoặc latent). Điều kiện đơn giản và inference nhanh.	Ưu: Nhanh, rẻ, dễ huấn luyện. Nhược: Không có tính ngẫu nhiên, khó ước lượng UQ.
Diffusion (Score-SDE)	Mô hình SDE thêm nhiễu rồi chạy ngược thời gian với mạng score (VD: DDPM, SDE của Song) 【6†L29-L34】.	Ưu: Có thể sinh đa dạng, lý thuyết vững. Nhược: Cần nhiều bước (NFE cao), chậm suy luận.
Flow Matching (FM)	Thuật toán ODE, huấn luyện trường vận tốc để dịch $z_p\to z^*$ không dùng nhiễu 【13†L23-L32】.	Ưu: Nhanh suy luận (ODE solver), ổn định. Nhược: Cần solver ODE, training có thể khó hội tụ.

Phương pháp	Đặc điểm	Ưu/Nhược chính
SB tiêu chuẩn (đẳng hướng)	Tìm diffusion path tối ưu giữa biên z_p và z^*, sử dụng KL đường đi【6†L29-L34】.	Ưu: Xác định chắc chắn về phân phối đầu-cuối; có thể học đẳng hướng hoá latent. Nhược: Training phức tạp, inference nhiều bước (không tối ưu như FM).
SB kênh-aware	Giống SB nhưng tham chiếu có thêm thông tin CSI (nhiễu theo reliability).	Ưu: Lý thuyết có thể nhanh đến đích hơn; nếu hiệu quả sẽ giảm bước. Nhược: Chưa có bằng chứng mạnh; khó huấn luyện và chọn tham chiếu.

Các chỉ số đánh giá:

- *Chất lượng nhiệm vụ:* mIoU (BEV seg) và AP (detection).
- *Uncertainty:* AUROC dự đoán lỗi, AURC (Area Under Risk-Coverage) và ECE (Expected Calib. Error) để đo độ tin cậy của SB.
- *Chi phí truyền:* bit/trái ban đầu (tổng token hoặc bit/trai) và số UAV cần kích hoạt.
- *Hiệu quả sinh mẫu:* NFE (số bước SB hoặc FM), thời gian tính toán, yêu cầu GPU.

Dữ liệu tham khảo:

Datasets	UAV/ Nodes	Task	Tác giả/tham khảo
Town3 (CoPerception-UAV)【33†L21-L27】	5 UAV	BEV segmentation (4 nhãn)【33†L102-L106】, object detection	Siheng Chen et al.
OPV2V【19†L37-L43】	xe (V2X)	3D object detection	Yue Hu et al., NeurIPS 2022
V2X-Sim【19†L37-L43】	xe (V2X)	3D object detection	Yue Hu et al.
DAIR-V2X (Mạng đa phương tiện)【19†L37-L43】	xe/địa điểm	detection, seg	Yue Hu et al.

Các kịch bản kênh và độ tin cậy: Testing qua ba cấp kênh: *Easy* (gần như không mất gói), *Mid* (tỉ lệ mất gói ~10–20%), *Severe* (mất gói nhiều). Đánh giá đủ để thấy phản ứng của SB tại các điều kiện khác nhau.

Bảng trực quan so sánh:

Phương pháp	Chất lượng (mIoU ↑)	Phản ứng với channel xấu	Tốc độ suy luận	Uncertainty (AUROC ↑)
Regression (M)	Cao (Tốt)	Giảm vừa phải	Rất nhanh	–
Regression+hetero	Tương đương M	Giảm tương đương	Rất nhanh	Có ước lượng
Flow Matching (NFE=4)	Khá	Giảm	Nhanh (ODE)	–

Phương pháp	Chất lượng (mIoU ↑)	Phản ứng với channel xấu	Tốc độ suy luận	Uncertainty (AUROC ↑)
SB đẳng hướng (NFE small)	Trung bình-cao	Giảm	Chậm (NFE>10)	Trung bình
SB kênh-aware	Dự kiến cao hơn	Ổn định hơn (mong đợi)	Tương SB	Cao (nếu học tốt)

Lưu ý: Các giá trị phải được đo thực nghiệm. Bảng trên là minh hoạ so sánh ý tưởng. Chúng ta cần đánh giá xem SB có vượt lên trên mapping về chất lượng và bất định thật sự hay không.

---

7. Kết luận và bước kế tiếp

Nghiên cứu SB cho UAV SemCom đang ở giai đoạn đầu. **Tiêu chí chính Q1** là: *Liệu SB mang lại giá trị thực khi khôi phục latent ngữ nghĩa trong kênh không lý tưởng không?* Nếu không (SB thua hoặc bằng mapping), ta sẽ loại bỏ SB khỏi pipeline chính và tập trung vào các chiến lược giao tiếp dựa trên thông tin giá trị (Q2) mà không dùng SB phức tạp. Ngược lại, nếu SB chứng tỏ ưu thế (đặc biệt ở điều kiện kênh xấu hay trong việc ước lượng bất định), thì sẽ tiếp tục triển khai SB cho Q2/Q3.

Nếu Q1 thành công: Ta sẽ có một nền tảng SB vững chắc để xây phần chọn helper (dựa trên bất định SB) và khảo sát các chế độ truyền hybrid. Trong trường hợp này, các bước kế tiếp bao gồm thử nghiệm thêm trên tập dữ liệu có overlap (như CoPerception động) để đánh giá quy mô và độ lỗi redunancy, và cuối cùng tích hợp SB với các chiến lược RL cho chọn đường bay và giao tiếp (Q2/Q3 đầy đủ).

Nếu Q1 thất bại: Kế hoạch pivot đã có sẵn là: dùng trực tiếp thông tin độ tin cậy (ví dụ $\mathbf{r}$) và các phương pháp nhẹ (mapping + UQ đầu ra, heuristic selection) để hoàn thiện phần giao tiếp dựa trên độ tin cậy. Ta vẫn tiếp tục xây dựng vòng kín perception–communication–decision (theo ngay đầu mục tiêu Q2) nhưng không kèm SB. Kết quả nghiên cứu vẫn mang tính khoa học khi chứng minh rõ ràng vai trò của SB: tồn tại hay không ở bài toán này.

Tóm tắt trả lời các câu hỏi:

- *SB có khác gì BridgeCodec/chuyển mã?* SB tập trung khôi phục latent ngữ nghĩa thực từ latent thiếu/hỏng, không chỉ đơn giản "dịch latent" giữa các UAV (như BridgeCodec gợi ý) mà tạo ra pathway tối ưu khôi phục thông tin.
- *Cấu trúc tổng quan của SwarmBridge:* Như sơ đồ kiến trúc trên. Ban đầu các UAV dùng cùng encoder, VQ, truyền token. Đầu thu dùng SB để khôi phục latent, và độ bất định hướng dẫn chọn UAV.
- *SB là diffusion có điều kiện?* Có thể xem SB như extension của diffusion: nếu lấy drift=0, SB iteration đầu giống diffusion có điều kiện【6†L29-L34】. SB chung là tối ưu hoá KL nên dùng ít noise hơn và đảm bảo kết quả cuối, thay vì đặt thời gian dài.
- *Reference stochastic process:* Với semantic, chọn Brownian motion trong latent space làm đơn giản; nếu dự đoán SNR, ta có thể làm SDE có ma trận cov phụ thuộc tin cậy. Với trajectory, dùng dynamics UAV (có nhiễu) hoặc chính sách bay an toàn làm nền. Brownian về không gian vị trí UAV sẽ không thực tế vì không tuân theo giới hạn vật lý.

Nguồn tham khảo: Báo cáo trích dẫn các bài chính【6†L29-L34】【8†L23-L31】【13†L23-L32】【19†L24-L32】【29†L481-L490】【33†L23-L27】 để minh hoạ lý thuyết và hướng tiếp cận. Chúng tôi

nhấn mạnh đọc [6,8,13] để nắm khái niệm SB/flow/diffusion, [19,22,29] để hiểu bài toán SemCom đa agent và hybrid modes, và [33] để hiểu dataset Town3.
